INSEGNAMENTO DI ANALISI DI DATI BIOLOGICI
LM in BIOINGEGNERIA – A.A.2025/2026

HOMEWORK 2

COGNOME: FELICE **NOME**: RICCARDO **MATRICOLA**: 2142812
/IL **DATA**: 22/01/2026
e-mail: riccardo.felice@studenti.unipd.it **allegati:** felice_h2_25.zip

ESERCIZIO H2_23 (EM)
Nei tracciati CGM (Continuous Glucose Monitoring) raccolti nella vita quotidiana possono essere presenti degli "artefatti da compressione" dovuti al fatto che il soggetto monitorato può inavvertitamente appoggiarsi in modo prolungato sul sensore, ad esempio durante il sonno. L'obbiettivo di questo homework è quello di sviluppare un algoritmo di fault detection capace di individuare retrospettivamente gli artefatti da compressione presenti nel tracciato CGM implementando un algoritmo di predizione a breve termine. Nello specifico, si individuerà un artefatto ogni volta che la differenza tra predizione e traccia CGM supera una certa soglia, come illustrato a pagina 58 delle slide parte 5.
Nel file sensor_data_1.mat è contenuto un tracciato CGM (in [mg/dL]), rilevato per 24 ore e campionato uniformemente ogni 5 minuti, in un soggetto affetto da diabete. Come si può evincere da un'ispezione visiva, il tracciato contiene (attorno al minuto 520 e al minuto 620) due distinti "artefatti da compressione".
Basandosi sull'esercizio 1 del laboratorio 7, realizzare uno script che, dati i campioni CGM affetti da artefatto, calcoli il valore predetto PH minuti in avanti mediante running line con pesi usando un forgetting factor mu.
Parametrizzare il codice rispetto a PH e mu e provare ad osservare a video l'effetto di diverse scelte dei valori dei parametri sulla predizione (es. testare varie combinazioni di valori, ad esempio: PH=20min, 25min, 30min, mu =0.86, 0.9, 0.99).
Realizzare una figura che, retrospettivamente, mostri in un primo riquadro il segnale CGM e la sua predizione, shiftata verso sinistra di PH minuti in modo che le due tracce siano temporalmente allineate.
Basandosi sull'ispezione delle differenze tra i due tracciati, mostrate in un secondo riquadro, individuare una combinazione di parametri PH e mu ed una soglia opportuna che permettano di minimizzare, e possibilmente evitare, i falsi allarmi, riuscendo però comunque a riconoscere i due artefatti (un esempio è riportato nella figura seguente).

ESERCIZIO H2_25 (EM)
Come nell'esercizio H2_23, ma basandosi sull'esercizio 2 del laboratorio 7 e quindi usando modello AR di ordine p identificato con i Recursive Least Squares (RLS) usando un forgetting factor mu. Testare varie combinazioni di valori (ad esempio: PH=20min, 25min, 30min; p=2, 4, 6; mu =0.86, 0.9, 0.99) ed utilizzare come valori iniziali della matrice P e del vettore dei parametri a quelli ottenuti tramite comandi: P = 100*eye(p);
ahat = (1/p)*ones(p,1);

SVOLGIMENTO

Metodologia

Per individuare gli artefatti da compressione prima di tutto ho implementato un modello autoregressivo (AR), aggiornandone i parametri in modo ricorsivo dentro al ciclo for attraverso l'algoritmo recursive least squares (RLS) con forgetting factor, adattando così il modello alla fisiologia del paziente, riducendo variazioni troppo brusche del segnale. Successivamente, ad ogni passo di campionamento (5 minuti), ho calcolato la predizione secondo il prediction horizon (PH) iterando il modello.

Infine sottraendo il dato reale dalla rispettiva predizione allineata, ho calcolato i residui, individuando gli allarmi, nei casi in cui il residuo superava la soglia.

Presentazione del codice

Nello script *homework_h2_25.m*:

- Sezione 1, caricati i dati dal file "'sensor_data_1.mat', è stato definito il tempo di campionamento, specificato dalla consegna, mentre il prediction horizon, il forgetting factor, l'ordine del modello e la soglia sono stati variati per controllare le performance del modello. Successivamente è stato calcolato il passo di predizione, in funzione di PH, dato che il tempo di campionamento è costante;
- Sezione 2, vengono inizializzate le variabili dell'algoritmo RLS, quindi sono stati definiti i vettori per i risultati, la matrice di covarianza P ed il vettore dei parametri ahat;
- Sezione 3, contiene il ciclo principale che itera lungo il segnale. Al suo interno vengono eseguite due operazioni: l'identificazione del modello AR, dove i parametri si aggiornano ricorsivamente, attraverso l'algoritmo RLS, quindi pesate dal forgetting factor (mu); successivamente la predizione, in cui il modello predice a L passi in avanti, fino a stimare il valore di glucosio all'orizzonte PH;
- Sezione 4, si occupa della fault detection, dove vengono calcolati i residui sottraendo il segnale misurato dalla predizione (allineata temporalmente). I campioni vengono valutati utilizzando una soglia di decisione;
- Sezione 5, plot unico con due grafici, in quello sopra il confronto tra la dinamica stimata ed il dato misurato, mentre nel secondo l'andamento dell'errore nel tempo con gli allarmi, dove l'errore supera la soglia.

Risultati e discussione

Tra tutte le combinazioni di parametri, si riportano di seguito tre configurazioni significative per mostrare l'impatto del forgetting factor e dell'ordine del modello.

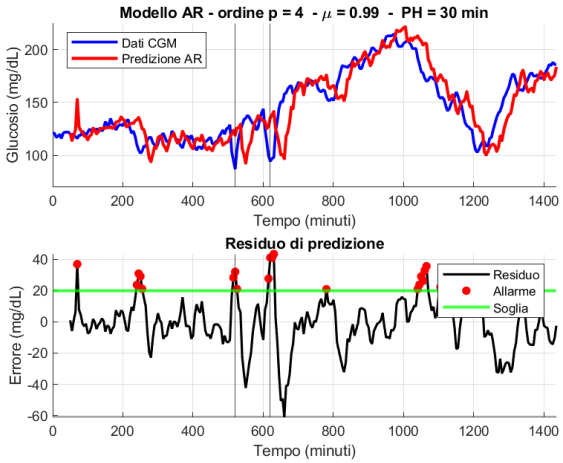


Figura 1. Il grafico sopra mostra l'andamento del glucosio nel tempo attraverso il segnale originale (blu) ed il segnale predetto dal modello (rosso). Il grafico sotto mostra l'andamento dei residui, la soglia e gli allarmi dove il residuo la supera.

In questo caso l'ordine del modello è pari a 4, il forgetting factor pari a 0.99 ed il prediction horizon è di 30 minuti. La predizione mostra un comportamento regolare. Di fronte ai crolli causati dagli artefatti ai minuti 520 e 620, il modello mantiene una traiettoria stabile e coerente con la storia passata, ignorando di fatto la discesa improvvisa. Questo assicura che il residuo rappresenti la discrepanza tra la misura predetta dal modello, ossia una misura coerente con i valori passati e la misura effettivamente misurata. Allarmi misurati: 30.

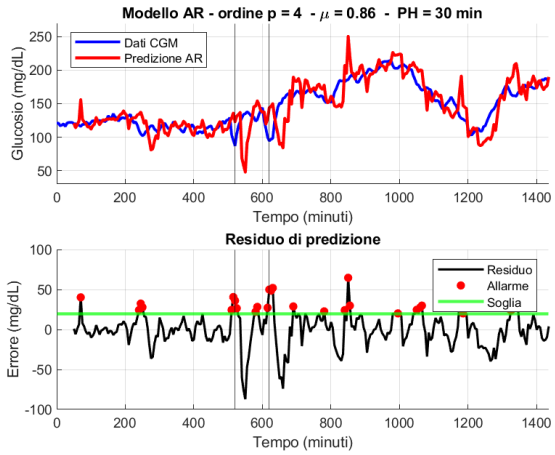


Figura 2. Mostra la stessa tipologia di grafico, variato solo il valore mu, pari a 0.86.

Rispetto al grafico precedente è stato variato esclusivamente il parametro mu, passando da 0.99 a 0.86. Si può notare come la predizione generata dal modello AR risulti più sensibile ed irregolare. Sempre ai tempi 520 e 620 minuti la traccia predetta insegue il crollo del segnale misurato, arrivando anche a scendere al di sotto di esso. Nonostante il numero di allarmi rispetto al caso precedente aumenti solamente di 1 (31 allarmi misurati), la predizione del segnale non risulta affidabile, sembra quasi una predizione affetta da rumore.

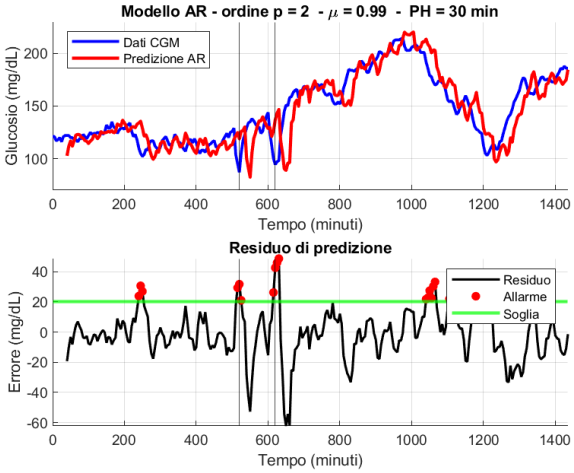


Figura 3. Mostra la stessa tipologia di grafico, mu torna a 0.99, varia l'ordine del modello.

Per questo caso ho modificato l'ordine del modello p, portandolo a 2, per renderlo più "leggero". I risultati sono stati soddisfacenti, ha diminuito in maniera considerevole gli allarmi, rilevandone 23. È un ottimo risultato, poiché vengono diminuiti anche i falsi allarmi, ovvero le zone che non sono intorno agli artefatti principali Il tutto è stato ottenuto utilizzando un modello più semplice, che risulta anche affidabile nella predizione di questo tracciato.

La scelta di ridurre l'ordine del modello a 2 si è rivelata una buona strategia per filtrare il rumore in maniera efficace riducendo i falsi positivi ed isolando gli eventi anomali ai tempi 520 e 620 min. Inoltre l'utilizzo di un modello di ordine inferiore comporta una riduzione della complessità computazionale; quindi un algoritmo meno esoso di risorse di calcolo si traduce in minor consumo energetico, che è la situazione ideale per estendere l'autonomia dei dispositivi indossabili, senza perdere dettagli importanti.